

卒業論文

# 飲食店推薦のための機械学習アルゴリズムの比較

関西学院大学 理工学部 情報科学科

27020729 須崎 良祐

2024年3月

指導教員：北村 泰彦 教授

# 内容梗概

本研究は、検索と推薦の違いに焦点を当て、特に飲食店の推薦において、どの機械学習アルゴリズムが最適かを明確化することを目的としている。検索はユーザーがアクティブに情報を求める一方で、推薦はユーザーの好みに基づいて自動的にアイテムを提示する。

本研究では、飲食店に関するデータを入力変数に変換し、飲食店に対する評価を目的変数に変換し、決定木、ロジスティック回帰、k-NN の 3 つのモデルで 10 フォールド交差検証を行った。

実験は、十分な飲食店情報と評価データが利用可能な場合と、それらの情報が限られている場合の両方で実施された。その結果、情報が豊富な場合には決定木が最良の結果を示した。一方、情報が限られている場合にはロジスティック回帰が最良の結果を示した。

この研究は、機械学習を用いた推薦アルゴリズムの開発において、使用するアルゴリズムの選択がデータの量や質に依存することを示している。それにより、各シナリオに最適なアルゴリズムの選定に関する洞察を提供している。

# 目次

第1章	はじめに	1
第2章	推薦システム	3
2.1	推薦システムに用いる用語の定義	3
2.1.1	推薦システムとは [1]	3
2.1.2	既存の推薦手法 [1]	3
2.2	推薦システムに関する研究	4
2.2.1	決定木を用いたユーザー群に対しての飲食店推薦 [2]	4
2.2.2	個人に対しての飲食店推薦 [3]	6
2.2.3	決定木を用いた個人に対しての音楽推薦 [4]	6
2.3	本研究の目的	6
第3章	飲食店推薦のための機械学習アルゴリズムの比較	7
3.1	飲食店推薦の概要	7
3.2	推薦に用いる飲食店データと特徴量	8
3.3	比較するアルゴリズム [5]	9
3.3.1	決定木	9
3.3.2	ロジスティック回帰	11
3.3.3	k-NN	14
第4章	評価	16
4.1	評価の目的	16
4.2	評価方法	16
4.3	評価指標	16
4.4	結果	17
4.4.1	10 フォールド交差検証で得られた結果	17
4.4.2	訓練データを増やした際の精度の推移	17
4.4.3	結果の考察	21
第5章	まとめ	22
	謝辞	23



# 目 次

3.1	機械学習を用いた飲食店推薦手法 . . . . .	7
3.2	決定木 . . . . .	12
3.3	得られた決定木 . . . . .	12
3.4	2点間の距離 . . . . .	15
4.1	10 フォールド交差検証で得られた精度 . . . . .	18
4.2	10 フォールド交差検証で得られた再現率 . . . . .	18
4.3	ユーザー 1 の決定木 . . . . .	19
4.4	ユーザー 2 の決定木 . . . . .	19
4.5	ユーザー 3 の決定木 . . . . .	20
4.6	訓練データを増やした際の精度の推移 . . . . .	20

# 表 目 次

2.1	飲食店の特徴量 . . . . .	4
2.2	ユーザーの飲食店に対する評価値 . . . . .	4
2.3	顧客情報と飲食店情報 . . . . .	5
3.1	飲食店データとその特徴量 . . . . .	8
3.2	ジャンル 13 種類の内訳 . . . . .	8
3.3	飲食店の特徴量とそれに対するユーザーの評価の例 . . . . .	9
4.1	決定木と他手法の精度における統計的な有意差 . . . . .	17

# 第1章 はじめに

飲食店推薦システムは、ユーザーの過去の行動や好みに基づき、自動的に関連する飲食店を提案する技術である。このようなシステムは、ユーザーがまだ発見していない新しい飲食店を提案することで、個人化された食体験を提供する。

これは、ぐるなびや食べログなどの検索システムとは明確に異なる。これらの検索システムでは、ユーザーは特定の検索条件を入力し、システムはそれに最も適した飲食店情報を提供する。一方で、推薦システムでは、ユーザーの飲食店に対する過去の評価を分析し、ユーザー自身が未知である可能性のある新しい飲食店を提案する。つまり、推薦は自動的にユーザーに対して飲食店情報を提供し、検索はユーザー自身が飲食店情報を見つけ出さなければならないのである。

ユーザーの手間がかからない点や新しい未知の飲食店を発見できる可能性が高い点は、飲食店推薦システムの大きな価値となっている。飲食店の推薦は、爆大な飲食店情報から、好みに合った飲食店の情報を提供する。

近年では推薦システムの研究は盛んに行われているが、本研究では2つの研究を関連研究として取り上げる。1つ目は、決定木を用いたユーザー群に対しての飲食店推薦システムの研究 [2] であるが、ユーザー群に対しての推薦システムになっているため、個人の好みに着目した推薦をすることができない。2つ目は、ユーザー個人の飲食店に対する評価によって価格帯とジャンルそれぞれに対する重み変動し、そのユーザーの好みに沿った飲食店を提示できる推薦システムの研究 [3] であるが、推薦に用いる飲食店情報として、価格帯とジャンルしか扱っていない。また、決定木を用いたユーザー個人で利用できる音楽推薦システムの研究 [4] もあり、決定木と他の機械学習アルゴリズムを比較して、決定木の有効性を示している。しかし、飲食店推薦の文脈で、どの機械学習アルゴリズムが有効であるか明確でない。

そこで、本研究では、飲食店推薦に、代表的な機械学習アルゴリズム（決定木、ロジスティック回帰、k-NN）のうち、どのアルゴリズムを使えば良いかを明確化する。

評価では、飲食店情報とそれに対するユーザーの評価を用いて、各機械学習アルゴリズムで10フォールド交差検証を行い、その性能を示す。また、学習用データを増やした際の精度の推移を示す。

本論文の構成は以下の通りである。第2章では、関連研究、及び本研究の目的について述べる。第3章では、本研究で比較する機械学習アルゴリズムの詳細について述べる。第4章では、結果その考察を述べる。第5章では、本研究のまとめと今

後の課題について述べる.



## 第2章 推薦システム

### 2.1 推薦システムに用いる用語の定義

#### 2.1.1 推薦システムとは [1]

推薦システムは、ユーザーの行動パターンに基づいて、商品、サービス、情報といったアイテムを自動的に提案するシステムである。このシステムの重要性は、インターネットの発展とともに急速に増しており、背景として情報過多の問題がある。現代のデジタル社会で、ユーザーが直面する情報の量が爆発的に増加し、関連性の高い、または興味を引くコンテンツを効率的に見つけることが困難になっているためである。

推薦システムは、この情報の海から有用な情報を引き出し、個々のユーザーにカスタマイズされた推薦を行うことで、情報選択のプロセスを簡素化し、ユーザー体験を向上させる。

推薦システムの開発は、ユーザーのニーズを理解し、パーソナライズされたサービスを提供することに重点を置いている。これにより、ユーザー満足度を高め、ビジネスにおいては顧客の関与を深め、売上向上に寄与することが期待される。

#### 2.1.2 既存の推薦手法 [1]

推薦システムにおいて広く使用される二つの主要な手法は、以下の通りである。

##### 内容ベースフィルタリング

内容ベースフィルタリングは、ユーザーのアイテムに対する過去の評価を分析し、アイテムの各特徴とユーザーの評価の関係をモデル化し、そのモデルを用いて新たなアイテムを推薦する手法である。つまり、アイテムの特徴に着目している。

表 2.1 において、ユーザー A に飲食店を推薦する場合を考える。ここでは、「無し」を0, 「有り」を1という特徴量にする。内容ベースフィルタリングの場合、ユーザー A が高評価した飲食店と似た特徴を持つ飲食店を推薦する。ユーザー A は、飲食店 A に高評価した場合、飲食店 A と最も類似度が高い飲食店 B をユーザー A に推薦する。

### 協調フィルタリング

協調フィルタリングは、多くのユーザーのアイテムに対する評価を分析し、似た評価パターンを持つユーザーを見つけ出し、新たなアイテムを推薦する手法である。

表 2.2 において、ユーザー A に飲食店を推薦する場合を考える。ここでは、「行きたくない」を 0, 「行きたい」を 1 という評価値にする。協調フィルタリングの場合、ユーザー A と似た評価パターンを持つユーザーを元に推薦を行う。ユーザー A は、ユーザー D と最も類似度が高い評価パターンを持つため、ユーザー D が「行きたい」と評価した飲食店 D をユーザー A に推薦する。

つまり、内容ベースフィルタリングはユーザーの評価とアイテムの特徴の関係をを用いる推薦手法であり、協調フィルタリングは他ユーザー、あるいは他アイテムの評価パターンを用いる推薦手法である。

本研究では、内容ベースフィルタリングを用いた推薦に焦点を当てている。

特徴/飲食店	飲食店 A	飲食店 B	飲食店 C	飲食店 D
喫煙席の有無	0	0	1	1
駐車場の有無	1	1	0	0
Wi-Fi の有無	1	0	0	0
個室の有無	1	1	0	1

表 2.1: 飲食店の特徴量

ユーザー/飲食店	飲食店 A	飲食店 B	飲食店 C	飲食店 D
ユーザー A	1	1	-	-
ユーザー B	1	0	1	1
ユーザー C	0	1	1	0
ユーザー D	1	1	0	1

表 2.2: ユーザーの飲食店に対する評価値

## 2.2 推薦システムに関する研究

### 2.2.1 決定木を用いたユーザー群に対しての飲食店推薦 [2]

この研究では、決定木を用いて、飲食店を低価格帯、中価格帯、高価格帯カテゴリに分類し、ユーザーを低予算、中予算、高予算カテゴリに分類し、各カテゴ

りがマッチする飲食店をユーザーに推薦するシステムの開発を行っている。この研究で用いたデータセットには表 2.3 のような 95 件の飲食店情報と、135 人の顧客情報と顧客のいくつかの飲食店に対する評価情報が含まれている。これらの情報を使って、ユーザーを各予算カテゴリ、飲食店を各価格帯カテゴリに分類する決定木を構築している。システムの構成として、顧客情報を入力し、それに基づいて飲食店情報が出力される。

しかし、この研究で開発しているシステムは、他人の顧客情報と飲食店に対する評価を使った推薦システムになっているため、個人の好みに着目した推薦を行うことができないという課題を抱えている。

顧客情報	飲食店情報
ユーザー ID	飲食店 ID
緯度	料理
経度	支払い方法
喫煙者かどうか	駐車場
飲酒レベル	平日の営業時間
服装の好み	土曜の営業時間
雰囲気	日曜の営業時間
交通手段	緯度
婚姻状況	経度
子供の有無	名前
生年	提供アルコール
興味・関心	喫煙エリア
性格	服装コード
宗教	アクセシビリティ
活動レベル	価格帯
色	雰囲気
体重	フランチャイズかどうか
予算	エリア
身長	その他のサービス
好きな料理の種類	
支払い方法	

表 2.3: 顧客情報と飲食店情報

### 2.2.2 個人に対しての飲食店推薦 [3]

この研究では、好みのジャンルを表す関数と、好みの価格帯を表す関数に基づいて飲食店を推薦するシステムの開発を行っている。飲食店情報（ジャンルと価格帯）から、飲食店の評価を行い、その飲食店が持つ各ジャンルと各価格帯に対する重みが、それぞれの関数内で変動する。システムの構成として、ユーザーは飲食店を選択し、その飲食店に対して評価（良い、悪い）を入力し、それに基づいて関数の重みが変動し、2つの関数によってユーザーの好みに合った新しい飲食店が推薦される。

しかし、この研究で開発しているシステムは、推薦に用いる飲食店情報として、価格帯とジャンルしか扱っていないという課題を抱えている。

### 2.2.3 決定木を用いた個人に対しての音楽推薦 [4]

この研究では、推薦に決定木、k-means、凝集法を用いた場合の評価を行い、決定木の有効性を示し、決定木を用いて音楽推薦システムの開発を行っている。システムの構成として、ユーザはいくつかの音楽データに対して評価（好き、嫌い、どちらでもない）を行い、その音楽データからシステムは曲の特徴量を抽出する。そして、ユーザの好みを表すユーザープロファイル（決定木）を作成し、それを元に推薦するかどうかを判定する。この研究で用いたデータセットには、200曲分の音楽データ（入力変数）と、それらに対する10人分の評価情報（目的変数）が含まれている。各機械学習アルゴリズムの評価では、これらのデータセットを用いて、ユーザーの評価情報の予測に、それぞれの機械学習アルゴリズムを用いた場合の性能の比較を行っている。

## 2.3 本研究の目的

関連研究が抱える課題を解決するためには、推薦に用いる飲食店情報として価格帯とジャンル以外の飲食店情報も扱えるようにし、個人の好みに着目した推薦を行えるようにする必要がある。また、飲食店推薦において、どういった機械学習アルゴリズムが適しているかを明確にする必要がある。そのため、木構造を使った決定木、線形モデルであるロジスティック回帰、非線形モデルであるk-NNのうち、どのアルゴリズムを使えばいいかを明確化する。

## 第3章 飲食店推薦のための機械学習 アルゴリズムの比較

### 3.1 飲食店推薦の概要

本研究で扱う機械学習を用いた飲食店推薦手法の構成は、図 3.1 の通りである。まず、複数の飲食店データとそれらに対する1人のユーザーの評価（行きたい、行きたくない）を用意する。そして、そのデータを特徴量に変換し、各機械学習アルゴリズムに学習させる。それぞれの学習済みモデルを使って、ユーザーの評価を予測し、それに基づいて飲食店を推薦する。




図 3.1: 機械学習を用いた飲食店推薦手法

## 3.2 推薦に用いる飲食店データと特徴量

本研究で扱う推薦に用いる飲食店データと特徴量は、表 3.1 の通りで、ジャンル 13 種類の内訳は、表 3.2 の通りである。これらは 0 か 1 といった離散値、0 から 1 にスケーリングされた連続値に変換される。なお飲食店データは、ホットペッパーグルメとぐるなびから収集したものである。

	飲食店データ	特徴量
ジャンル (13 種類)	なし, あり	0, 1 のベクトル
個室の有無	なし, あり	0, 1
喫煙席の有無	禁煙, 一部禁煙, 禁煙不可	0, 0.5, 1
Wi-Fi の有無	なし, あり	0, 1
駐車場の有無	なし, あり	0, 1
価格帯	0～1000, 1001～2000...	0 から 1 の連続値
総合評価	1 から 5 の、小数点以下 2 桁	0 から 1 の連続値

表 3.1: 飲食店データとその特徴量

ジャンル
中華
居酒屋
和食
お好み焼き・もんじゃ
韓国料理
イタリアン・フレンチ
焼肉・ホルモン
洋食
アジア・エスニック料理
創作料理
各国料理
ラーメン

表 3.2: ジャンル 13 種類の内訳

### 3.3 比較するアルゴリズム [5]

特徴/飲食店	駐車場の有無	個室の有無	喫煙席の有無	ユーザーの評価値
飲食店 A	1	1	1	0
飲食店 B	1	0	0	1
飲食店 C	1	0	1	0
飲食店 D	1	1	0	1
飲食店 E	0	1	0	0
飲食店 F	0	0	1	-

表 3.3: 飲食店の特徴量とそれに対するユーザーの評価の例

#### 3.3.1 決定木

決定木とは、木構造を用いて条件分岐を繰り返し、分類や回帰を行う機械学習の手法である。本研究では、目的変数が 0（行きたくない）、1（行きたい）といった離散値を取るため、分類を用いる。

決定木では、以下のようなノード  $t$  におけるエントロピー  $I(t)$  を考える。

$$I(t) = - \sum_{i=1}^c \frac{n_{ti}}{N_t} \log_2 \frac{n_{ti}}{N_t}$$

$c$  は目的変数のクラス数、 $N_t$  はノード  $t$  における訓練データのサンプル数、 $n_{ti}$  はノード  $t$  におけるクラス  $i$  に属する訓練データの数である。本研究では、0（行きたくない）、1（行きたい）の 2 クラスの分類を用いるため、 $c = 2$  となる。

ここで、図 3.2 のような木構造を考える。エントロピーを使って、以下のように、条件  $H$  でノード  $A$  からノード  $B$  に分岐させた時の利得  $\Delta I_H(A \rightarrow B)$  を計算する。

$$\Delta I_H(A \rightarrow B) = I(A) - \sum_{i=1}^b \frac{N_{B_i}}{N_A} I_H(B_i)$$

$b$  は分岐の数である。本研究では図 3.2 のような 2 分木を用いるため、 $b = 2$  となる。

このような利得が最大になるような条件を探し、分岐を繰り返す。なお、本研究では、全ての葉ノードで、片方のクラスのデータのみが格納されるまで分岐を繰り返す。そして、得られた木構造を元に、属するクラスを予測する。

表 3.3 のような飲食店 A, B, C, D, E の特徴量と、それらに対するユーザーの評価値を使って、飲食店 F を推薦するかどうかを考える。まず、ルートノード  $A$  には飲食店 A, B, C, D の特徴量とそれらに対するユーザーの評価値が含まれる

ため、初期のエントロピー  $I_H(X)$  は以下の通りである.

$$I(A) = \frac{2}{5} \log_2 \frac{5}{2} + \frac{3}{5} \log_2 \frac{5}{3} = 0.97$$

次に、どのような条件で子ノード  $B$  に分岐させると、利得が高いのかを求める. 駐車場の有無  $P$  を条件とし、子ノード  $B$  に分岐させた場合は以下の通りである.

$$\begin{aligned} \Delta I_P(A \rightarrow B) &= I(A) - \sum_{i=1}^2 \frac{N_{B_i}}{N_A} I_P(B_i) \\ &= 0.97 - \left\{ \frac{1}{5} \left( \frac{1}{1} \log_2 \frac{1}{1} + \frac{0}{0} \log_2 \frac{0}{0} \right) + \frac{4}{5} \left( \frac{2}{4} \log_2 \frac{4}{2} + \frac{2}{4} \log_2 \frac{4}{2} \right) \right\} \\ &= 0.17 \end{aligned}$$

個室の有無  $R$  を条件とし、子ノード  $B$  に分岐させた場合は以下の通りである.

$$\begin{aligned} \Delta I_R(A \rightarrow B) &= I(A) - \sum_{i=1}^2 \frac{N_{B_i}}{N_A} I_R(B_i) \\ &= 0.97 - \left\{ \frac{2}{5} \left( \frac{1}{2} \log_2 \frac{2}{1} + \frac{1}{2} \log_2 \frac{2}{1} \right) + \frac{3}{5} \left( \frac{2}{3} \log_2 \frac{3}{2} + \frac{1}{3} \log_2 \frac{3}{1} \right) \right\} \\ &= 0.02 \end{aligned}$$

喫煙席の有無  $S$  を条件とし、子ノード  $B$  に分岐させた場合は以下の通りである.

$$\begin{aligned} \Delta I_S(A \rightarrow B) &= I(A) - \sum_{i=1}^2 \frac{N_{B_i}}{N_A} I_S(B_i) \\ &= 0.97 - \left\{ \frac{3}{5} \left( \frac{1}{3} \log_2 \frac{3}{1} + \frac{2}{3} \log_2 \frac{3}{2} \right) + \frac{2}{5} \left( \frac{2}{2} \log_2 \frac{2}{2} + \frac{0}{0} \log_2 \frac{0}{0} \right) \right\} \\ &= 0.42 \end{aligned}$$

結果として、ルートノード  $A$  から子ノード  $B$  に分岐させる条件は、「喫煙席の有無」であった. 「喫煙席の有無」という条件で分岐させると、ノード  $B_1$  は片方のクラスのデータのみが格納されている状態になり、これ以上分岐できない.



ノード  $B_2$  のエントロピー  $I_H(B_2)$  は以下の通りである.

$$I(B_2) = \frac{1}{3} \log_2 \frac{3}{1} + \frac{2}{3} \log_2 \frac{3}{2} = 0.92$$

次に, 「喫煙席の有無」以外でどのような条件で子ノード  $D$  に分岐させると, 利得が高いのかを求める. 駐車場の有無  $P$  を条件とし, 子ノード  $D$  に分岐させた場合は以下の通りである.

$$\begin{aligned} \Delta I_P(B_2 \rightarrow D) &= I(B_2) - \sum_{i=1}^2 \frac{N_{D_i}}{N_{B_2}} I_P(D_i) \\ &= 0.92 - \left\{ \frac{1}{3} \left( \frac{1}{1} \log_2 \frac{1}{1} + \frac{0}{0} \log_2 \frac{0}{0} \right) + \frac{2}{3} \left( \frac{0}{0} \log_2 \frac{0}{0} + \frac{2}{2} \log_2 \frac{2}{2} \right) \right\} \\ &= 0.92 \end{aligned}$$

個室の有無  $R$  を条件とし, 子ノード  $D$  に分岐させた場合は以下の通りである.

$$\begin{aligned} \Delta I_R(B_2 \rightarrow D) &= I(B_2) - \sum_{i=1}^2 \frac{N_{D_i}}{N_{B_2}} I_R(D_i) \\ &= 0.92 - \left\{ \frac{1}{3} \left( \frac{0}{0} \log_2 \frac{0}{0} + \frac{1}{1} \log_2 \frac{1}{1} \right) + \frac{2}{3} \left( \frac{1}{2} \log_2 \frac{2}{1} + \frac{1}{2} \log_2 \frac{2}{1} \right) \right\} \\ &= 0.25 \end{aligned}$$

結果として, ルートノード  $B_2$  から子ノード  $D$  に分岐させる条件は, 「駐車場の有無」であった. 「駐車場の有無」という条件で分岐させると, ノード  $D_1$ , ノード  $D_2$  は片方のクラスのデータのみが格納されている状態になり, これ以上分岐できない. これで全ての葉ノードで片方のクラスのデータのみが格納されている状態になるため, 図 3.3 のような木構造が構築される. 飲食店 E は青色のノード  $B_1$  に格納され, 飲食店 E に対する予測評価値は 0 になるため, 飲食店 E を推薦しない.

実装には, 機械学習ライブラリである Scikit-Learn の DecisionTreeClassifier クラスを使っている.

### 3.3.2 ロジスティック回帰

ロジスティック回帰とは, 線形モデルの 1 つであり, 陽性クラス（本研究では「行きたい」のクラス）に属する確率を用いて, 2 クラス分類を行う機械学習の手

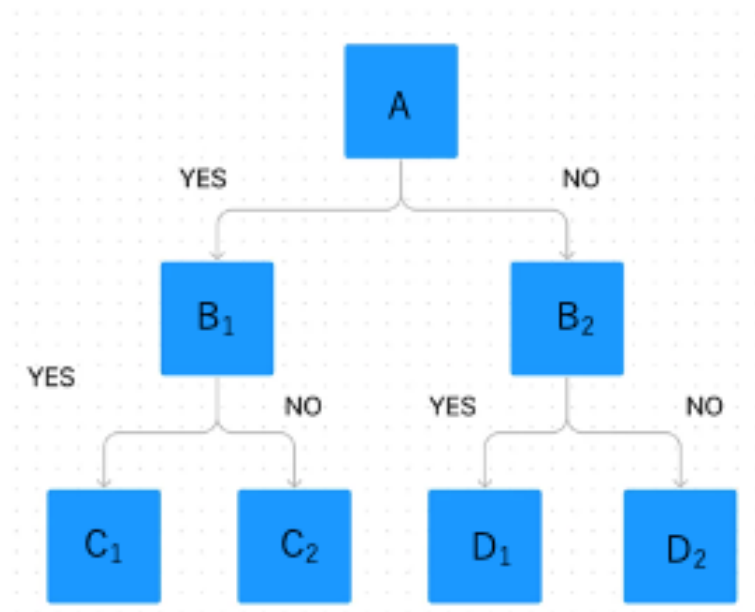


図 3.2: 決定木

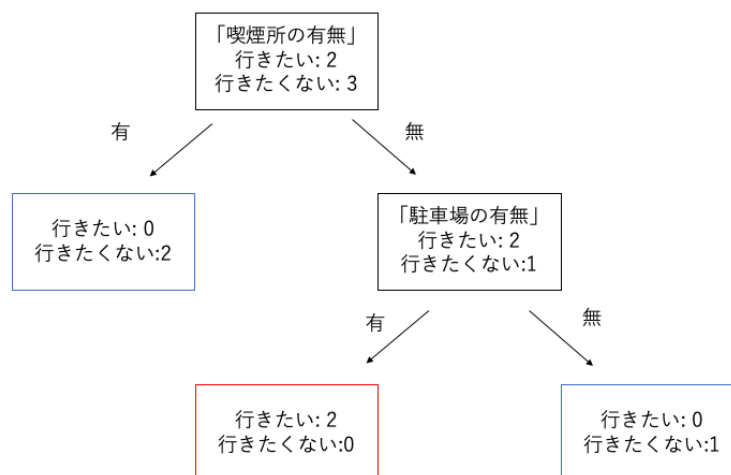


図 3.3: 得られた決定木

法である。本研究では、目的変数が0（行きたくない）、1（行きたい）の2クラスを取るため、この手法を用いることができる。

ロジスティック回帰では、以下のようなシグモイド関数  $\sigma(t)$  を考える。

$$\sigma(t) = \frac{1}{1 + e^{-t}}$$

シグモイド関数  $\sigma(t)$  に、 $t = \sum_{i=0}^n w_i x_i$  を代入し、陽性クラスに属する確率  $\hat{p}$  を求める。

$$\hat{p} = \sigma \left( \sum_{i=0}^n w_i x_i \right)$$

$n$  は特徴量の数、 $x_i$  は  $i$  番目の特徴量、 $w_i$  は  $i$  番目の特徴量に対する重みである。本研究では、特徴量の数は、表 3.1 と表 3.2 で示した通りで、19 なので、 $n = 19$  となる。下記のような損失関数  $E(w_i)$  を考える。

$$E(w_i) = -\frac{1}{m} \sum_{j=1}^m [y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j)]$$

$m$  は訓練データの数、 $y_j$  は  $j$  番目のデータに対する目的変数、 $\hat{p}_j$  は  $j$  番目のデータが陽性クラスに属する確率、 $w_i$  は  $i$  番目の重みである。損失関数  $E(w_i)$  を用いた勾配降下法で、最適な  $w$  を見つける。重み  $w_i$  はランダムな値から開始し、収束するまで下記のような勾配降下を行う。

$$w_i \leftarrow w_i - \frac{\partial E(w_i)}{\partial w_i} * \alpha$$

$\alpha$  は学習率である。そして、予測モデル  $\hat{y}$  は、以下のように定式化される。

$$\hat{y} = \begin{cases} 0 & \text{if } \hat{p} \leq 0.5 \\ 1 & \text{if } \hat{p} > 0.5 \end{cases}$$

この予測モデルは、陽性クラスに属する確率が0.5以下であれば、陰性クラスと予測し、陽性クラスに属する確率が0.5を超えていれば、陽性クラスと予測することを示している。

表 3.3 のような飲食店 A, B, C, D, E の特徴量と、それらに対するユーザーの評価値を使って、飲食店 F を推薦するかどうかを考える。ここで、駐車場の有無を  $x_1$ 、個室の有無を  $x_2$ 、喫煙席の有無を  $x_3$  とする。また、それらに対する重みを

それぞれ  $w_1$ ,  $w_2$ ,  $w_3$  とする. 損失関数  $E(w_i)$  は以下のように定義される.

$$\begin{aligned} E(w_i) &= -\frac{1}{5} \sum_{j=1}^5 [y_j \log(\hat{p}_j) + (1 - y_j) \log(1 - \hat{p}_j)] \\ &= -\frac{1}{5} (\log(1 - \hat{p}_1) + \log(\hat{p}_2) + \log(1 - \hat{p}_3) + \log(\hat{p}_4) + \log(1 - \hat{p}_5)) \end{aligned}$$

損失関数  $E(w_i)$  を用いた勾配降下を行うと,  $w_1 = 0.375$ ,  $w_2 = -0.152$ ,  $w_3 = -0.656$  となった. 飲食店 E が陽性クラスに属する確率  $\hat{p}_e$  は以下の通りである.

$$\begin{aligned} \hat{p}_e &= \sigma(0.375 * 0 + (-0.152) * 0 + (-0.656) * 1) \\ &= 0.342 \end{aligned}$$

飲食店 E が陽性クラスに属する確率は 0.5 以下であるため, 飲食店 E を推薦しない.

実装には, 機械学習ライブラリである Scikit-Learn の LogisticRegression クラスを使っている.

### 3.3.3 k-NN

k-NN とは, 非線形モデルの 1 つで, 近傍データ  $k$  個で多数決を行い, クラス分類を行う機械学習の手法である. 本研究では, 目的変数が 0 (行きたくない), 1 (行きたい) の 2 クラスを取るため, この手法を用いることができる.

本研究では, 図 3.4 のような訓練データの特徴ベクトル  $x$  と予測対象のデータの特徴ベクトル  $y$  の距離を考える. 計算に以下のようなユークリッド距離  $d(x, y)$  を用いる.

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

$n$  は特徴量の数,  $x_i$  は訓練データの  $i$  番目の特徴量,  $y_i$  は, 予測対象であるデータの  $i$  番目の特徴量. 本研究では, 特徴量の数は, 表 3.1 と表 3.2 で示した通りで, 19 なので,  $n = 19$  となる. つまり, 最も予測対象のデータ  $y$  と近い訓練データ  $x$  を  $k$  個見つけ, その  $k$  個の目的変数の多数決によって, 属するクラスを予測するのである.

表 3.3 のような飲食店 A, B, C, D, E の特徴量と、それらに対するユーザーの評価値を使って、飲食店 F を推薦するかどうかを考える。ここで、飲食店 E の  $i$  番目の特徴量を  $y_i$ 、その他の飲食店の  $i$  番目の特徴量を  $x_i$ 、 $k = 1$  とする。飲食店 F と飲食店 A のユークリッド距離は 1.41、飲食店 F と飲食店 B のユークリッド距離は 1.41、飲食店 F と飲食店 C のユークリッド距離は 1.0、飲食店 F と飲食店 D のユークリッド距離は 1.73、飲食店 F と飲食店 E のユークリッド距離は 1.41 となる。つまり、近傍データ 1 つは飲食店 C となり、飲食店 E に対する予測評価値は 0 になるため、飲食店 E を推薦しない。

実装には、機械学習ライブラリである Scikit-Learn の KNeighborsClassifier クラスを使っている。




図 3.4: 2 点間の距離

## 第4章 評価

### 4.1 評価の目的

飲食店推薦に、どの機械学習アルゴリズムを用いることが有用であるかどうかを調べるため.

### 4.2 評価方法

以下の手順で、各アルゴリズムの評価を行う.

- ・3人から飲食店100件分に対して、「行きたい」「行きたくない」といった評価データを取得する.

- ・3人分のデータセットを用いて、各手法の10フォールド交差検証を行い、精度と再現率を算出する.

- ・10フォールド交差検証で得られた各手法の精度間に統計的な有意差があるかどうかをウィルコクソンの符号順位検を用いて確認する.

- ・それぞれのアルゴリズムで訓練データの数を10から90まで増やした際の、精度の推移を確かめる

### 4.3 評価指標

本研究では、各機械学習アルゴリズムの性能を、以下のような評価指標を用いて評価する.

#### 精度

陽性クラスと予測したもののうち、実際に陽性クラスだったものの割合.

#### 再現率

実際に陽性クラスだったもののうち、陽性クラスと予測したものの割合.

また、最も良かった手法と他の手法の精度に有意差があるかどうかを、以下の検定を用いて確認する。

#### ウィルコクソンの符号順位検

2 群間の数値に統計的な有意差があるかを調べるためのノンパラメトリック検定。

## 4.4 結果

### 4.4.1 10 フォールド交差検証で得られた結果

各アルゴリズムで 10 フォールド交差検証を行ったところ、精度はグラフ 4.1、再現率はグラフ 4.2 のようになった。精度、再現率ともに決定木が最も良かった。また、決定木と他のアルゴリズムの精度に、統計的な有意差が存在するかどうかを調べるために、10 フォールド交差検証の精度を使ってウィルコクソンの符号順位検を行い、その結果を表 4.1 に示している。ランダム手法と決定木の間では、ユーザー 3 人において、有意水準 1 % で有意差が見られた。なお、ランダム手法はテストデータを全て「行きたい」と予測する手法である。ロジスティック回帰と決定木の間と k-NN と決定木の間では、ユーザー 2 人において、有意水準 5 % で有意差が見られた。

また、ユーザー 3 人の 1 フォールド目の決定木をそれぞれ図 4.3、図 4.4、図 4.5 に示している。ユーザー 3 は単純なルールで飲食店を選択しており、それに対して、ユーザー 1 とユーザー 2 は複雑なルールで飲食店を選択していることが分かる。

手法/ユーザー	ユーザー 1	ユーザー 2	ユーザー 3
ランダム手法	○	○	○
ロジスティック回帰	○	○	×
k-NN	×	○	○

表 4.1: 決定木と他手法の精度における統計的な有意差

### 4.4.2 訓練データを増やした際の精度の推移

各アルゴリズムにおいて、訓練データを増やした際の精度の推移をグラフ 4.6 に示している。訓練データが少ない状況では、ロジスティック回帰が最も良い精度を示し、逆に訓練データが多い状況では、決定木最も良い精度を示した。




図 4.1: 10 フォールド交差検証で得られた精度




図 4.2: 10 フォールド交差検証で得られた再現率



[illegible]

図 4.3: ユーザー 1 の決定木

Decision tree for Fold 1

```

graph TD
    Root["中絶 <= 0.003  
entropy = 1.0  
samples = 90  
value = [84, 6]"]
    Root --> Left["結局評価 <= 3.034  
entropy = 0.937  
samples = 60  
value = [24, 44]"]
    Root --> Right["和食 <= 0.723  
entropy = 0.439  
samples = 22  
value = [20, 2]"]
    
    Left --> Left1["中絶 <= 0.0  
entropy = 0.999  
samples = 50  
value = [24, 26]"]
    Left --> Left2["entropy = 0.0  
samples = 10  
value = [0, 10]"]
    
    Left1 --> Left1a["ラーメン <= 0.841  
entropy = 0.994  
samples = 44  
value = [24, 20]"]
    Left1 --> Left1b["entropy = 0.0  
samples = 6  
value = [0, 6]"]
    
    Left1a --> Left1a1["焼肉・ホルモン <= 0.648  
entropy = 0.971  
samples = 40  
value = [24, 16]"]
    Left1a --> Left1a2["entropy = 0.0  
samples = 4  
value = [0, 4]"]
    
    Left1a1 --> Left1a1a["お好み焼き・もんじゃ <= 0.963  
entropy = 0.918  
samples = 30  
value = [24, 12]"]
    Left1a1 --> Left1a1b["entropy = 0.0  
samples = 2  
value = [0, 2]"]
    
    Left1a1a --> Left1a1a1["結局評価 <= 2.367  
entropy = 0.774  
samples = 34  
value = [24, 10]"]
    Left1a1a --> Left1a1a2["entropy = 0.0  
samples = 6  
value = [0, 6]"]
    
    Left1a1a1 --> Left1a1a1a1["結局改善 <= 2.802  
entropy = 0.968  
samples = 21  
value = [11, 10]"]
    Left1a1a1a --> Left1a1a1a2["解法料理 <= 0.636  
entropy = 0.65  
samples = 12  
value = [2, 10]"]
    
    Left1a1a1a1 --> Left1a1a1a1a1["青魚料理 <= 0.648  
entropy = 0.439  
samples = 11  
value = [5, 10]"]
    Left1a1a1a1a1 --> Left1a1a1a1a2["予算 <= 2171.102  
entropy = 1.0  
samples = 2  
value = [1, 1]"]
    
    Left1a1a1a1a1 --> Left1a1a1a1a1a1["entropy = 0.0  
samples = 1  
value = [0, 9]"]
    Left1a1a1a1a1a1 --> Left1a1a1a1a1a2["entropy = 0.0  
samples = 1  
value = [0, 1]"]
    
    Left1a1a1a1a1a1 --> Left1a1a1a1a1a1a1["entropy = 0.0  
samples = 1  
value = [0, 9]"]
    Left1a1a1a1a1a1a1 --> Left1a1a1a1a1a1a2["entropy = 0.0  
samples = 1  
value = [0, 1]"]
    
    Right --> Right1["entropy = 0.0  
samples = 2  
value = [0, 2]"]
    Right --> Right2["entropy = 0.0  
samples = 2  
value = [0, 2]"]
  
```

図 4.4: ユーザー 2 の決定木

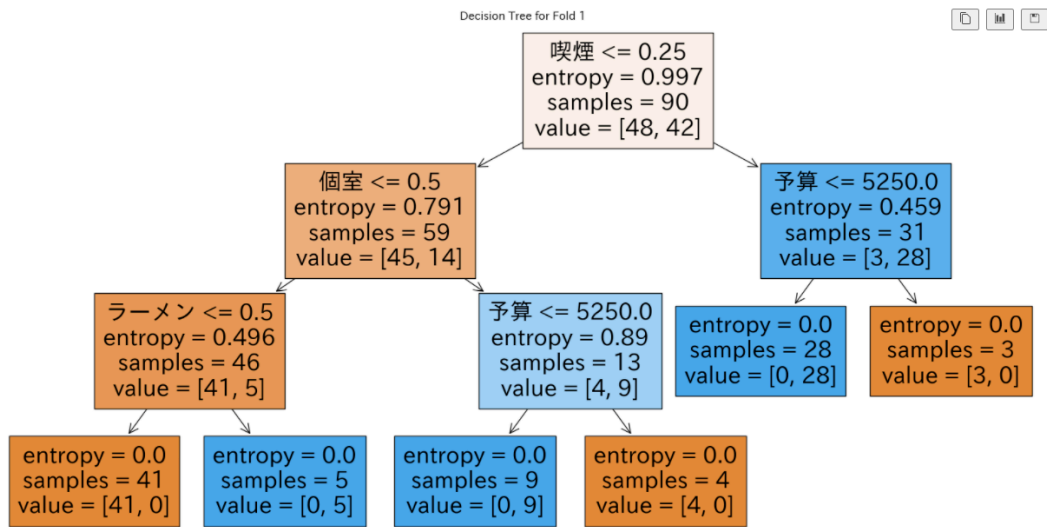


図 4.5: ユーザー 3 の決定木




図 4.6: 訓練データを増やした際の精度の推移

### 4.4.3 結果の考察

各アルゴリズムについての結果の考察を以下に述べる.

#### k-NN

終始決定木よりも悪い結果となった原因として、特徴量の重みが考慮できていないことが考えられる.

#### ロジスティック回帰

訓練データが少ない状況で最も良い結果を示した原因として、訓練データが少ない場合でも素早くデータに適合できることが考えられる. 訓練データが多い状況で決定木よりも悪い結果となった原因として、ロジスティック回帰は線形モデルなので、複雑なルールで飲食店を評価しているユーザーに対して適合しきれないことが考えられる.

#### 決定木

訓練データが少ない状況でロジスティック回帰よりも悪い結果となった原因として、訓練データが少ない場合だと、木構造を使ったモデルは線形モデルに比べて過学習しやすいことが考えられる. 訓練データが多い状況で最も良い結果となった原因として、木構造を使ったモデルなので、複雑なルールで飲食店を評価しているユーザーにも柔軟に適合できることが考えられる.

ユーザーのデータが十分に集まる環境であれば、内容ベースフィルタリングを用いた飲食店推薦には決定木を応用するのが最も良いと言える.

## 第5章 まとめ

研究の目的と結果を簡潔に書く．今後の課題に関して簡潔に書く．

# 謝辞

本研究を進めるにあたり，終始ご指導下さった北村泰彦教授に深く感謝いたします。

また，飲食店の評価に協力して頂いた友人3名にお礼申し上げます。

北村研究室の同輩諸氏には，日頃から多くのご助言やご支援をいただき，大変感謝しています。

最後に，4年間大学に通わせてくれた両親に，心から感謝しています。

## 参考文献

- [1] 神嶋敏弘. 推薦システムのアルゴリズム (1) . 人工知能学会, 22 巻 6 号, 2007.
- [2] Surajit Ghosh Dastidar. Restaurant recommendation system. *International Journal of Business Analytics and Intelligence*, 2017.
- [3] 児玉礼, 北山大輔. ユーザーの取捨選択行動に基づく嗜好情報による飲食店推薦システム. 第 8 回データ工学と情報マネジメントに関するフォーラム, F2-2, 2016.
- [4] 土方嘉徳, 岩濱数宏, 西田正吾. 決定木を用いた内容に基づく音楽情報フィルタリングとその有効性の検証. 情報処理学会, 研究報告, 2004.
- [5] Aurélien Géron. scikit-learn、Keras、TensorFlow による実践機械学習. オライリー・ジャパン, 2020.